

Sistema di supporto alla decisione terapeutica in cardiologia

Relazione di progetto — Natural Language Processing for Digital Health, 2026

Un sistema che legge referti di ricovero cardiologico in italiano, ne estrae lo stato clinico con tre pipeline diverse, lo codifica in ICD-10 e ATC, lo mette in un knowledge graph con la provenienza di ogni fatto, e propone la terapia di dimissione passando da un filtro di sicurezza simbolico e da un ranker misurato contro le decisioni vere dei cardiologi. Il tutto è esposto come server MCP a un modello conversazionale, con una traccia che dice *per quali parole del referto* una proposta esiste.

Il brief del progetto è in [docs/brief.md](#); un documento per step in [docs/](#), con [docs/00_architettura.md](#) come indice; [docs/guida_al_codice.md](#) spiega il codice modulo per modulo.

Indice

1. [Il progetto in una pagina](#)
2. [Il dataset e i vincoli](#)
3. [Architettura](#)
4. [La parte NLP: dal testo allo stato del paziente](#)
5. [Il knowledge graph](#)
6. [Il motore di raccomandazione](#)
7. [Il server MCP](#)
8. [Valutazione](#)
9. [Scelte implementative e alternative scartate](#)
10. [Limiti e lavoro futuro](#)
11. [Esecuzione](#)

1. Il progetto in una pagina

Compito. Dato un referto — anamnesi in prosa, terapia all'ingresso, terapia alla dimissione — proporre le classi di farmaci da **aggiungere** alla dimissione, con la motivazione come cammino nel grafo di conoscenza. La verità di riferimento era già nei dati: la terapia che il cardiologo ha davvero prescritto, su **841** ricoveri.

Che cosa ha funzionato

- Ogni codice viene da una knowledge base citata: 94% dei farmaci risolti ad ATC via AIFA con metodo e fonte per voce; 10 803 codici ICD-10 estratti dal PDF ufficiale italiano.
- Sul testo libero il modello linguistico vince: richiamo **70,1%** sulle condizioni contro 19,5% del gazetteer e 19,9% del NER, misurato su 25 referti annotati a mano. Sui campi strutturati il parser

deterministico fa 100% gratis.

- Il knowledge graph con la provenienza ha smascherato un «consenso a tre pipeline» del 46,6% che era una lettura contata tre volte: il valore vero è 14,8%.
- Il filtro simbolico non blocca a vuoto: su 5 863 prescrizioni reali, 91,3% ammesse e 4 vietate; e ha prodotto il principio più riusato del progetto — *una regola che dipende da un fatto che il sistema non estrae segnala, non vieta*.
- La traccia risponde «da dove viene?» in SPARQL; il server MCP espone sei strumenti di sola lettura, e un modello locale sceglie quello giusto 9 volte su 10.

Che cosa non ha funzionato

- Il ranker «migliore» non è distinguibile da un contatore di frequenza che non guarda il paziente: richiamo@5 **48,5% contro 47,5%**, differenza [-1,5%, +3,4%] in validazione incrociata a 5 pieghe. A livello di sostanza (7 caratteri ATC) l'ibrido è invece avanti di 4–9 punti, [+4,1%, +8,7%]: «il migliore» dipende dall'unità di misura.
- Il ranker con modello linguistico perde di 22–29 punti contro quel contatore (21,7% su tutti gli 841 ricoveri): propone la cardiologia giusta e manca il **40,4%** delle prescrizioni che cardiologia non è.
- Il guadagno «gerarchico» (contare gli antenati ATC) era aritmetica: lo guadagna anche un ranker casuale.
- Il NER addestrato su etichette silver non trova ciò che il gazetteer non trova, e ciò che trova in più non sa codificarlo; il NER clinico italiano pre-addestrato trovato su Hugging Face vede 2,5 volte più condizioni con precisione 31%.
- Le garanzie finiscono al confine dello strumento: un modello davanti al server MCP ha riscritto «iperteso» in «Ipotensione» con una catena di provenienza formalmente corretta. Ora è contato; non è impedibile.

Rumore di fondo del progetto: due punti percentuali. È la variazione fra corse dello stesso modello sugli stessi record e fra ricampionamenti dello stesso campione. Una differenza più piccola non è un risultato.

2. Il dataset e i vincoli

`data/raw/anamnesiterapie.txt`: un array JSON di **1 000** ricoveri cardiologici, pseudonimizzati, esportati dal sistema ospedaliero. Tre referti per ricovero:

CAMPO	PRESENTE IN	LUNGHEZZA MIN / MEDIANA / MAX	NATURA
Anamnesi	1 000	222 / 1 665 / 17 590 caratteri	prosa libera
Terapia medica all'ingresso	1 000	4 / 275 / 1 899	lista con ; , nomi commerciali
Terapia alla Dimissione	857	15 / 649 / 2 281	voci fra virgolette, principio attivo

Nella stessa cartella c'erano due varianti «più ricche», con i campi già separati e un questionario di condizioni: erano il grezzo passato per un modello linguistico, e sono state scartate. Costruire tre pipeline di estrazione sopra un'estrazione fatta da un modello avrebbe misurato quella.

I vincoli, e il perché.

VINCOLO	PERCHÉ
solo dati grezzi	i derivati misurerebbero l'estrazione di qualcun altro
ogni mappatura da una knowledge base citabile (AIFA, ICD-10 2019, ESC)	un modello produce codici plausibili e non verificabili; una voce non coperta si marca, non si inventa
si conserva tutto	le voci non risolte restano marcate: servono a vedere che cosa è stato mancato
il dataset non si versiona	è dell'ospedale; <code>data/</code> è in <code>.gitignore</code>
la sicurezza è sempre simbolica	il filtro non impara dal dataset e non chiede a un modello: ogni regola porta la fonte e si contesta riga per riga
tre esiti, non due	un falso blocco nega una terapia, un falso permesso lascia passare una controindicazione
prima il modello locale, si paga solo con numeri misurati	spesa totale del progetto in inferenza: 4,79 \$

3. Architettura

![[Il flusso dei dati]](file:///home/Carlo/Code/Natural Language Processing/docs/img/flusso.png)

Il referto entra in tre pipeline indipendenti che producono lo stesso oggetto `StatoPaziente`; il grafo di provenienza le tiene insieme; filtro e ranker lavorano sui soli fatti affermati del paziente, leggendo le regole dal grafo di conoscenza; la traccia interroga entrambi i grafi; il server MCP espone tutto a un modello conversazionale. **Tre pipeline e non una** perché lo scopo è confrontare metodi di estrazione; **il filtro è simbolico per vincolo** perché una regola di sicurezza deve poter essere contestata da un clinico.

STRATO	MODULI (SRC/)	STEP
dati e knowledge base	<code>data_loading</code> , <code>explore_dataset</code> , <code>fetch_external_kb</code> , <code>build_vocabularies</code> , <code>extract_icd10</code> , <code>normalize_drugs</code>	0, 1, 2, 2b
contratto dati	<code>schema</code> (<code>StatoPaziente</code> , <code>Pydantic</code>)	1
estrazione	<code>gazetteer</code> + <code>context_it</code> + <code>extract_a</code> · <code>llm_backend</code> + <code>extract_b</code> · <code>silver_labels</code> + <code>ner_train</code> + <code>ner_infer</code> + <code>entity_linking</code> + <code>extract_c</code>	3, 4, 5
codifica condivisa	<code>risolutori</code>	3–5
confronto e riferimento	<code>confronto</code> , <code>referimento</code>	6, 6bis
grafi	<code>kb_build</code> + <code>conoscenza</code> (conoscenza clinica, <code>kb/conoscenza.ttl</code>) · <code>grafo</code> + <code>interroga</code> + <code>traccia</code> (provenienza)	7, 9ter
decisione	<code>filtro</code> , <code>ranker</code> , <code>valuta_ranker</code> , <code>demo</code>	8, 9, 9bis
esposizione	<code>mcp_server</code> , <code>mcp_client_locale</code> , <code>valuta_mcp</code>	10
valutazione	<code>valuta_gerarchica</code>	11

Ogni modulo ha il suo file di test; 471 test, nessuno usa la rete.

4. La parte NLP: dal testo allo stato del paziente

4.1 Il contratto dati: `StatoPaziente`

Le tre pipeline producono lo stesso oggetto (Pydantic v2), che è l'unico input del motore:

```
class StatoPaziente(BaseModel):
    enc_oid: int; pipeline: Pipeline; versione_schema: str = "1.1.0"
    condizioni: list[CondizioneEstratta] # testo_grezzo, concetto, codice ICD-10, stato,
    soggetto, provenienza
    farmaci: list[FarmacoEstratto] # nome_grezzo, codice_atc, momento
    (ingresso/dimissione/narrativo), provenienza
    allergie: list[AllergiaEstratta] # allergene, categoria, codice_atc, provenienza
    stato_sezione_allergie: StatoConoscenza # ignoto / negato / affermato
```

Tre scelte reggono tutto il resto. **Tre stati di conoscenza** (affermato, negato, incerto) e non un booleano: «non riferisce angina» è la stessa parola con verità opposta. **Il soggetto separato dallo stato** (paziente, familiare): «padre deceduto per infarto» è vero e non è del paziente — l'asse è stato aggiunto nella versione 1.1.0 dopo che il confronto dello step 6 ha trovato un flutter atriale del *feto* attribuito alla paziente. **Provenienza obbligatoria** su ogni entità: pipeline, campo, offset di carattere, regola che l'ha prodotta. Lo stato della sezione allergie è separato dalla lista: sezione assente, «non note» e lista vuota sono tre cose diverse per un filtro di sicurezza.

4.2 Normalizzazione: vocabolari chiusi e knowledge base

Ogni campo il suo metodo. I due campi di terapia sono liste con delimitatori: si leggono con un parser (100% sull'ingresso, misurato) e sono una verità gratuita. La prosa richiede riconoscimento.

Il vocabolario chiuso (brief §3.1) viene dal dataset — 406 principi attivi, 923 nomi commerciali, 249 condizioni candidate — e definisce lo *scope*, non le relazioni. La risoluzione ad ATC usa il registro AIFA con una **cascata di sei strategie**, dal più stretto al più largo, ognuna registrata nella voce:

STRATEGIA	ESEMPIO	VOCI
principio esatto	Bisoprololo → C07AB07	296
associazione (/ nel dataset, «E» in AIFA)	Rosuvastatina / ezetimibe → C10BA06	12
commerciale esatto	Congescor → C07AB07	629
commerciale abbreviato (sigla del produttore dai titolari AIC)	pantoprazolo sand → A02BC02	188
suffisso salino / forma salina	Warfarin sodico → B01AA03; Enoxaparina → B01AB05	21

94% delle occorrenze risolte; le ambiguità ([lyrica](#): due ATC) restano marcate; i NIL sono voci fuori registro ([ferrograd](#), 64 occorrenze).

La terminologia ICD-10 viene dal PDF dell'Elenco Sistemático 2019 (890 pagine, [pdftotext -layout](#)): 10 803 codici, 14 898 termini con i parentetici espansi. Il confronto di stringhe con le condizioni del dataset copre il 18% e produce collegamenti sbagliati («non versamento pericardico» → versamento pericardico): la codifica non può essere un confronto di stringhe, e la polarità va decisa dal contesto.

4.3 Pipeline A — deterministica: gazetteer + ConText

`PhraseMatcher` di spaCy sulle forme dei vocabolari (farmaci da `mappatura_atc.json`, condizioni dai termini ICD filtrati e arricchiti di varianti senza qualificatori). Poi **ConText riscritto per l'italiano** (l'algoritmo è di Harkema et al. 2009, doi:10.1016/j.jbi.2009.05.002):

- **marcatori** con attributo, direzione e ampiezza, ricavati contando nel corpus: `non` 2 665 occorrenze, `nega` 522, `assenza di` 370, `senza` 319, `negativo per` 102; `sospetto` 134; `pregressa` 253;
- **terminatori** che chiudono l'ambito (`ma`, `riferisce`, punteggiatura); l'interazione fra `non` e il terminatore `riferisce` lasciava «non riferisce angina» affermato: `non riferisce` è ora un marcatore composto, giustificato da 48 occorrenze nel corpus;
- **asse del soggetto**: un ambito di familiarità aperto da «familiarità per», «madre», «padre deceduto per»... con una massima ampiezza, che assegna `soggetto = familiare`.

Esempio (paziente sintetico): «Non riferisce angina né cardiopatia ischemica. Padre deceduto a 60 anni per infarto miocardico. Segue cura per ipertensione arteriosa dal 2019.» → `I51.9 cardiopatia: negato / paziente, I10 ipertensione: affermato / paziente`; l'infarto del padre non diventa una condizione del paziente.

Su 1 000 record: 5 237 condizioni (299 negare), 83% con codice; 14 235 farmaci, 93,5% con ATC. Precisione alta, richiamo basso: il gazetteer vede solo ciò che è nel vocabolario.

4.4 Pipeline B — modello linguistico

Che cosa si chiede al modello, e che cosa no. Lo schema che riceve (`EstrazioneLLM`) non ha campi per i codici: un modello produrrebbe ATC e ICD plausibili ma non tracciabili a una fonte; i codici li assegnano i risolutori condivisi, dopo. Si chiede la **citazione letterale** di ogni menzione, cercata nel testo: se non c'è, la menzione è *non ancorata* e conta — è il rilevatore di allucinazioni, 0,3% sulla corsa finale. L'unico campo interpretativo è `concetto`, l'acronimo sciolto, usato come chiave di ricerca nell'indice ICD e mai creduto sulla parola (`BBS` → «blocco di branca sinistra» → `I44.7`, dove il gazetteer non ha appigli). Il modello legge **solo l'anamnesi**: i campi di terapia li legge il parser.

Backend intercambiabili e cache. `BackendLLM.genera(Richiesta) -> Risposta` con tre implementazioni (Ollama in locale, OpenRouter a consumo, fittizio per i test) e una cache su disco per impronta della richiesta (`sha256(modello + istruzioni + testo + schema + temperatura)`), in cui ogni risposta porta i propri token e costo. Una metrica nuova sulle stesse risposte è gratis; il costo si somma dai file.

La scelta del modello, misurata. Gemini gratuito: 20 richieste al giorno. `qwen3:4b` locale su GPU Radeon: 159–235 s per record, 65 ore per il corpus. `deepseek/deepseek-v4.1-flash` via OpenRouter: 1 000 record in 39 minuti, 2,42 \$; con il prompt finale 1,65 \$. La decisione di pagare è stata presa con i token misurati sulla corsa locale in cache, non con una stima.

I difetti erano del prompt. Un esempio positivo nel prompt (`mdc`) è stato ricopiato come allergia 105 volte; una regola che definiva i farmaci come «contenuto delle sezioni di terapia» faceva omettere tutti i farmaci narrati (0/60 sul riferimento → 83,3% dopo la correzione); un array senza `maxItems` non termina sotto decodifica vincolata (310 voci da 91 candidati). Cinque difetti su sette erano nelle istruzioni, non nel modello.

4.5 Pipeline C — NER + entity linking

Un NER è un classificatore di token che deve aver visto esempi etichettati. Il brief esclude l'annotazione manuale e prescrive la supervisione debole: etichette **silver** dall'uscita della pipeline A (7 649 menzioni), divisione per ricovero 700/150/150, fine-tuning di **IVN-RIN/bioBIT** (Buonocore et al. 2023, doi:10.1016/j.jbi.2023.104431 — un BERT italiano continuato su testo biomedico) su CPU, tre epoche in un'ora, allineamento caratteri → sottotoken con la mappa di offset, valutazione per entità: F1 0,869 sulla prova. Il NER trova 228 menzioni che il gazetteer non ha (**dronedarone**, **pericardite**) ed evita 95 suoi errori: ha imparato il contesto, non il vocabolario. Ma non sa codificarle: -142 condizioni con codice, +231 ambigue. La similarità ortografica come collegatore sbaglia 3 volte su 6 con il punteggio più alto sull'errore peggiore (**insufficienza mitralica moderata** → **...congenita**): declassata a proposta **AMBIGUO**, mai al filtro. Gli acronimi (**BPC0**, **FA**) non sono risolvibili da nessuna fonte citabile.

Il pre-addestrato che il brief chiede di valutare prima. Su Hugging Face esiste un solo NER clinico italiano, **HUMADEx/italian_medical_ner** (Sallauka et al. 2025, doi:10.3390/app15105585). Sui 25 referti del riferimento: condizioni richiamo 51,7% ma precisione 31,0%; farmaci precisione 3,6%; e nessun codice. Sposta il problema dal riconoscimento al linking senza risolverlo.

4.6 Confronto e riferimento

Sulla prosa le tre pipeline vedono cose diverse: 12 511 punti visti dalla sola B, 325 dalla sola C, 145 dalla sola A. Aggiudicando a mano un campione delle esclusive: B precisione 91,7% ± 3,6, A 73,3% ± 8,1, C 66,7% ± 8,6 — ma **gli errori di A arrivano già codificati 7 volte su 8**, quelli di C mai. Un riferimento annotato a mano su 25 referti (559 condizioni, 60 farmaci narrati; linee guida fissate prima; un solo annotatore, limite dichiarato) misura il richiamo:

! [Richiamo per pipeline](file:///home/Carlo/Code/Natural Language Processing/docs/img/graf-estrazione.png)

CONDIZIONI	PRECISIONE	RICHIAMO	F1
A · gazetteer	80,1%	19,5%	31,4%
B · modello linguistico	96,1%	70,1%	81,1%
C · NER	81,6%	19,9%	31,9%

Nessuna pipeline vince: sono tre profili di errore. Il progetto le usa insieme, con la provenienza.

5. Il knowledge graph

Due grafi RDF (**rdflib**), con lo stesso spazio di nomi per i concetti.

La conoscenza clinica — **kb/conoscenza.ttl**, versionato, 805 triple — è il grafo del brief §3.3: nodi **Drug** (classi ATC, con etichetta AIFA), **Condition** (ICD-10), **Guideline** (documento citato); relazioni reificate **Indicazione** (27: farmaco → condizione, classe di raccomandazione ESC, motivo, fonte, eventuale terapia che la innesca, fatto non estratto) e **Controindicazione** (12: esito, fonte RCP/ESC, fatti che la revocano). Lo script **kb_build.py** le dichiara e scrive il Turtle; **conoscenza.py** lo legge; **ranker e filtro prendono le regole da lì**, e un test verifica che il Turtle nel repository sia identico a quello rigenerato.

![[Il grafo di conoscenza](file:///home/Carlo/Code/Natural Language Processing/docs/img/conoscenza.png)]

Perché la curatela è manuale e non importata: la sonda su Wikidata (372 dei 439 principi attivi trovati, 273 con «condizione trattata», 158 con interazioni) mostra che la copertura c'è, ma senza classe di raccomandazione, senza fonte citabile e senza codice ICD-10 per la condizione. Le interazioni farmaco-farmaco non ci sono, e l'assenza è dichiarata.

La provenienza — [data/processed/grafico.ttl](#), 1,2 M triple, non versionato — modella **la menzione come nodo**: l'asserzione clinica è derivata (PROV-O) dalle menzioni sovrapposte che la sostengono, ciascuna attribuita al suo agente.

![[Il modello del grafo di provenienza](file:///home/Carlo/Code/Natural Language Processing/docs/img/grafico.png)]

```
ricoveri 1 000 · menzioni 69 533 · asserzioni 32 716
sostenute da 1 agente 76,3% · 2 agenti 8,9% · 3 agenti 14,8%
```

Il 46,6% di consenso a tre riportato in prima battuta era il parser dei campi strutturati contato come tre agenti: il grafo esiste esattamente per rendere interrogabile questo tipo di domanda (`COUNT(DISTINCT ? agente)`). Il grafo **non decide**: non fonde le contraddizioni, non scarta le menzioni irrisolte (40,8% delle condizioni senza codice). La decisione è dello step 8.

6. Il motore di raccomandazione

6.1 Fase 1 — il filtro di sicurezza, simbolico

Quattro famiglie di regole: allergia alla sostanza (vietato), allergia al sottogruppo ATC (da verificare: la reattività crociata non è un divieto), duplicazione terapeutica, controindicazione per condizione (12 regole con fonte RCP 4.3 o ESC). Solo le condizioni **affermate e del paziente** controindicano. Il verdetto è il massimo dei motivi.

Provato contro le 5 863 prescrizioni reali: 91,3% ammesse, 8,6% da verificare, **4 vietate**. La prima versione ne vietava 28: ventiquattro erano betabloccanti in pazienti con blocco AV e *pacemaker*, che nessuna pipeline estrae. Da qui il **principio del fatto mancante**: una regola la cui premessa richiede un fatto che il sistema non sa stabilire segnala, non vieta. È ricomparso cinque volte nel progetto.

Il richiamo del filtro non ha una verità; venti casi avversari attraverso l'estrazione ne coglie 14. I sei mancati sono tutti termini che il vocabolario chiuso non conosce («ASA», «aspirina», «asma bronchiale»): il richiamo del filtro è limitato dall'estrazione, non dalle regole.

6.2 Fase 2 — i ranker

L'unità è la **classe ATC** a cinque caratteri (`C07AB`, non il bisoprololo). Il compito è ordinare le classi da **aggiungere**: 2 075 decisioni su 841 ricoveri, perché copiare la terapia d'ingresso copre già il 63,6% della dimissione.

RANKER	COME DECIDE
continuità	ripropone la terapia in atto (linea di base del compito 1)
frequenza	le classi più aggiunte nel reparto, senza guardare il paziente
simbolico	il peso della migliore indicazione ESC che scatta (I 1,0 · IIa 0,6 · IIb 0,3): il massimo, non la somma
ibrido	$\log P(\text{classe}) + \max \text{PMI}(\text{condizione}, \text{classe}) + \text{peso} \times \text{simbolico}$ — a evidenza zero ricade sulla frequenza, per costruzione
con modello linguistico	il modello ordina i candidati già filtrati; i codici fuori elenco vengono scartati e contati

Il tetto, noto prima di misurare. Il 40,4% delle prescrizioni non è cardiologia (gastroprotettori 525, antidiabetici, potassio...): nessuna linea guida cardiologica le regola, e un ranker a linee guida ha un tetto per costruzione.

7. Il server MCP

`MCPServer` dell'SDK `mcp 2.x`, sei strumenti con `read_only_hint=True`, nessun argomento che indichi un ricovero (il corpus non passa di qui):

STRUMENTO	RISPONDE A
<code>cardio_proponi_terapia</code>	che cosa aggiungere — dal testo
<code>cardio_proponi_da_stato</code>	idem — da uno <code>StatoPaziente</code> (la firma del brief §3.5, schema Pydantic generato)
<code>cardio_sostegno_del_concetto</code>	da dove viene questo fatto (SPARQL)
<code>cardio_verifica_sicurezza</code>	il verdetto del filtro; rifiuta ciò che non è un codice
<code>cardio_cerca_codice</code>	ATC e ICD-10 per nome o codice
<code>cardio_statistiche_corpus</code>	solo aggregati

Ogni proposta dichiara il **fondamento** (indicazione citata, oppure co-occorrenza misurata con avvertimento), i fatti mancanti e il ranker usato. Due client: Claude Code e un host locale con `qwen3.5:4b` via ollama. Dieci domande scritte prima, due corse: strumento giusto 9/10, testo intatto 6/6, risposte 10/10. Tre difetti trovati alla frontiera — proposte a tasso di base presentate come fondate, l'anamnesi **parafrasata** («iperteso» → «Ipotensione»), il filtro che diceva «ammesso» a un nome invece di un codice — tutti corretti o resi visibili; la parafrasi resta contabile, non impedibile.

8. Valutazione

Protocollo. Unità: classe ATC. Compito: le aggiunte. Metrica primaria: `richiamo@5` (una decisione giusta per ricovero, non tutte: la precisione non è interpretabile come correttezza); metriche gerarchiche per livello ATC e hP/hR/hF (Kiritchenko 2005; Silla & Freitas 2011, doi:10.1007/s10618-010-0175-9).

Validazione incrociata a 5 pieghe con pieghe deterministiche per hash del ricovero e insieme candidato ricostruito per piega; **bootstrap** su 1 000 ricampionamenti *dei ricoveri* con differenze appaiate; un **ranker casuale a seme fisso** come controllo.

8.1 Il risultato principale

! [Richiamo@5 per ranker](file:///home/Carlo/Code/Natural Language Processing/docs/img/graf-ranker.png)

RANKER · 5 PIEGHE, 841 RICOVERI	RIC@3	RIC@5	RIC@10	MAP	INTERVALLO RIC@5
casuale	3,2%	5,3%	10,8%	0,075	[4,0%, 6,5%]
continuità	10,1%	10,6%	13,2%	0,108	[9,1%, 12,2%]
simbolico	15,8%	23,7%	29,2%	0,185	[21,5%, 25,8%]
frequenza	32,6%	47,5%	65,2%	0,402	[44,8%, 50,3%]
ibrido	36,8%	48,5%	67,2%	0,425	[45,7%, 51,1%]
deepseek-v4.1-flash, tutti gli 841 con i candidati della divisione singola	15,8%	21,7%	33,7%	0,205	[19,4%, 24,0%]

DIFFERENZA APPAIATA (RIC@5)	INTERVALLO 95%
ibrido – frequenza	[−1,5%, +3,4%] include lo zero: indistinguibili
ibrido – simbolico	[+21,7%, +28,0%] esclude lo zero
frequenza – simbolico	[+20,9%, +26,9%] esclude lo zero
deepseek – frequenza	[−29,2%, −22,5%] esclude lo zero

8.2 Il controllo casuale: il guadagno gerarchico era aritmetica

! [Richiamo per livello ATC](file:///home/Carlo/Code/Natural Language Processing/docs/img/graf-livelli.png)

Contare come centrato un antenato del codice giusto alza il richiamo di tutti, ranker casuale compreso (dal 7,2% al 57,3% dal quarto al primo livello). Sopra il caso il vantaggio dell'ibrido passa da +45,9 a +44,4: niente. E al primo livello deepseek sta sotto il caso: propone la cardiologia giusta e il 40,4% dei bersagli non è cardiologia. Trappola trovata misurando: troncare i codici può abbassare il richiamo, perché due bersagli centrati (C03CA, C03DA) collassano in un C03 solo — 15 casi reali, e un test lo fissa.

8.3 «Il migliore» dipende dall'unità

Con l'unità = sostanza (7 caratteri, il quinto livello ATC del brief):

5 PIEGHE, UNITÀ SOSTANZA	RIC@5	HF
frequenza	38,0%	42,9%
ibrido	44,3%	44,4%
simbolico	9,4%	19,6%
ibrido – frequenza	[+4,1%, +8,7%]	[+0,5%, +2,6%]

A livello di classe l'ibrido e la frequenza sono indistinguibili; a livello di sostanza l'ibrido è avanti di 4–9 punti e il simbolico crolla, perché una linea guida indica la classe, non la molecola: dentro la classe decide la co-occorrenza. Il richiamo assoluto è più basso (44% contro 48%) perché il bersaglio è più fine.

8.4 La spiegabilità, contata invece che affermata

Quante proposte fra le prime cinque hanno almeno un'indicazione ESC che scatta per quel paziente, e quante fra quelle centrate:

5 PIEGHE, CLASSE	PROPOSTE MOTIVATE	CENTRI MOTIVATI
frequenza	20,9%	30,8%
ibrido	29,5%	34,8%
simbolico	68,4%	81,7% (ma centra la metà: 464 contro 904)

Il vantaggio di spiegabilità dell'ibrido sulla frequenza è di quattro punti, non una differenza di categoria: due terzi dei suoi centri sono «in questo reparto si fa», e il sistema lo dice per ogni proposta. Il ranker davvero spiegabile è il simbolico, che trova la metà.

8.5 L'estrazione conta poco sul ranking

Metrica secondaria del brief: la stessa valutazione con lo stato estratto da ciascuna pipeline. Ibrido 48,9% (A), 48,5% (B), 49,0% (C); simbolico 21,2% (A e C) contro 23,7% (B). Il richiamo più alto di B sulle condizioni vale 2,5 punti al ranker simbolico — al pavimento di rumore — e nulla all'ibrido, dominato dalla frequenza.

8.6 La provenienza

![Consenso prima e dopo](file:///home/Carlo/Code/Natural Language Processing/docs/img/graf-consenso.png)

9. Scelte implementative e alternative scartate

SCELTA	PERCHÉ	ALTERNATIVA SCARTATA
rdflib e un file Turtle, non un database a grafo	nessun server da installare per la discussione; SPARQL standard; 1,2 M triple stanno in memoria (41 MB); il grafo di conoscenza è un file versionabile e leggibile	Neo4j / GraphDB: un servizio da amministrare per un progetto individuale
filtro e ranker non passano dal grafo	una SPARQL costa 12,43 ms, una lettura da dizionario 0,073 µs; sul ciclo di valutazione (841 × migliaia di candidati) sono ore contro secondi. La traccia sì, perché serve <i>dopo</i>	tutto via SPARQL
estrazione deterministica come predefinita nella demo e nel server	zero rete, zero chiavi, zero denaro, riproducibile; il modello è opzionale (<code>--motore</code>)	il modello sempre attivo: un server che chiama un modello per rispondere a un modello paga due volte
prior empirico nell'ibrido (co-occorrenza)	il 40,4% delle prescrizioni non è in nessuna linea guida; senza il prior il ranker ha un tetto per costruzione	solo linee guida: 23,7% di richiamo
unità = classe ATC	la molecola è del prontuario; il brief ammette la classe; misurato anche a sostanza (§8.3)	sostanza come unica unità
Pydantic per il contratto dati	validazione all'ingresso, JSON Schema generato (usato dal tool MCP e dal prompt), enumerazioni chiuse	dizionari: nessun contratto
urllib per i backend LLM	due funzioni; nessun SDK che cambia; la cache e i ritentativi sono nostri e testati	SDK dei fornitori
cache per impronta della richiesta	rimisurare è gratis; il costo si somma dai file; la valutazione è ripetibile su risposte non deterministiche	richiamare il modello a ogni metrica
PhraseMatcher spaCy per il gazetteer	offset esatti, tokenizzazione italiana, migliaia di forme in un passo	regex: una per forma
ConText riscritto, non medspaCy	i marcatori sono in inglese; i nostri vengono contati nel corpus	tradurre medspaCy
bioBIT, non un BERT generalista	il lessico clinico italiano è nel suo pre-addestramento; un generalista lo frammenta in sottotoken	bert-base-italian-xxl-cased (resta un parametro)
modello locale prima, remoto solo con token misurati	65 ore contro 1,65 \$: la scelta è stata fatta con i numeri, non con una stima	remoto per comodità
il modello non riceve né produce codici	la conoscenza interna non è citabile; i codici li danno AIFA e ICD-10	chiedere al modello il codice
tre esiti nel filtro	falso blocco e falso permesso fanno entrambi danno	ammesso / vietato
ranker casuale come controllo, prima dei risultati	senza, i 4–7 punti gerarchici sarebbero stati raccontati come un risultato	nessun controllo
bootstrap sui pazienti, differenze appaiate	le prescrizioni dello stesso ricovero non sono indipendenti	intervalli non appaiati

10. Limiti e lavoro futuro

- **Il riferimento annotato è di un solo annotatore**, che è anche l'autore delle pipeline: nessun accordo inter-annotatore. Mitigato (annotazione alla cieca, linee guida scritte prima, correzioni tracciabili), non risolto.
 - **Il richiamo del filtro è limitato dal vocabolario chiuso**: un allergene scritto fuori dalle forme del corpus («aspirina», «ASA») non risolve, e ora è dichiarato come fatto mancante. Un filtro reale cercherebbe l'allergene nell'intero registro AIFA a runtime.
 - **Le interazioni farmaco-farmaco non ci sono**. Wikidata ne offre 4 372 a livello di sostanza (P769): sarebbe la prima estensione, con lo stesso script di import.
 - **La frazione di eiezione, il punteggio CHA₂DS₂-VA, i valori di laboratorio e i dispositivi impiantati** sono i fatti che più limitano le regole, e nessuna pipeline li estrae.
 - **Il dosaggio non è modellato**: una raccomandazione senza posologia è incompleta.
 - **La parafrasi è contata, non impedita**. La difesa vera è un [resource](#) MCP che il client apre da file: un disegno diverso.
 - **Dieci domande sono una misura piccola** per il server MCP; la lista è scritta per essere estesa a costo zero.
 - **Non è un dispositivo medico**. La verità è una decisione di un medico per ricovero.
-

11. Esecuzione

Python $\geq$ 3.10; dipendenze in [requirements.txt](#), motivate una per una.

```
pip install -r requirements.txt
python3 -m spacy download it_core_news_sm
python3 src/fetch_external_kb.py          # AIFA, con manifest in kb/
ollama pull qwen3.5:4b                   # il modello locale (step 9 e 10)

python3 -m unittest discover -s tests -q  # 471 test, nessuna rete
python3 src/demo.py --esempio 1 --traccia # un paziente dall'inizio alla fine
python3 src/demo.py --interattivo         # la tua anamnesi da tastiera
python3 src/kb_build.py --figura           # rigenera kb/conoscenza.ttl e la figura
python3 src/valuta_gerarchica.py --pieghe 5 # la valutazione finale, gratis
python3 src/valuta_gerarchica.py --pieghe 5 --sostanza
claude mcp add cardio -- python3 src/mcp_server.py
python3 src/mcp_client_locale.py --strumenti # handshake col server
python3 src/valuta_mcp.py                  # le dieci domande (ollama, ~1 h)
```

Il dataset va in [data/raw/anamnesiterapie.txt](#); il PDF ICD-10 in [data/external/](#). Le corse con modello linguistico sono in cache per impronta di richiesta: rieseguire una valutazione non chiama il modello. La chiave OpenRouter sta in [.env.local](#), mai nel codice.

Struttura

src/	un modulo per step, più schema, backend LLM, conoscenza
tests/	471 test su dati sintetici
docs/	un documento per step, l'indice, la guida al codice, il brief, le figure
kb/	conoscenza.ttl (il grafo clinico) e manifest_fonti.json
notebooks/	quattro notebook di analisi, senza output salvati
data/	non versionato: grezzo, knowledge base scaricate, intermedi, uscite
.claude/	skill di progetto per Claude Code

Fonti. AIFA, liste dei farmaci (CC-BY 4.0) · ICD-10 2019 Elenco Sistemático, Centro Collaboratore OMS FVG, via reclassificazioni.it · ESC 2019–2024 (scompenso, fibrillazione atriale, sindromi coronariche, diabete, ipertensione, dislipidemie), citate una per una in [kb/conoscenza.ttl](#) · ConText, Harkema et al. 2009 · bioBIT, Buonocore et al. 2023 · HUMADEx Italian Medical NER, Sallauka et al. 2025 · PROV-O, W3C 2013 · Qwen3.5 4B via Ollama, DeepSeek V4.1 Flash via OpenRouter — motori, non fonti di conoscenza · [anthropics/skills mcp-builder](#), con provenienza dichiarata in [.claude/skills/](#).